

Einführung in die Forschungsmethoden der Psychologie und Psychotherapie

Einheit 2: Messen in der Psychologie

24.04.2025 | Prof. Dr. Caroline Zygar-Hoffmann

Termine

Einheit	Datum	Thema
1	10.04.2025	Psychologie als Wissenschaft Teil 1
1	17.04.2025	Psychologie als Wissenschaft Teil 2
2	24.04.2025	Messen in der Psychologie
-	01.05.2025	Feiertag (Termin entfällt)
3	08.05.2025	Verhaltensbeobachtung
4	15.05.2025	Befragungen & Tests
5	22.05.2025	Kausalität, Experiment und Studiendesigns
-	29.05.2025	Prüfungswoche / Feiertag (Termin entfällt)
6	05.06.2025	Gastvortrag (Fokus: Forschung mit biopsychologischen Methoden)
7	12.06.2025	Qualitative Methoden: Verstehen des Einzelfalls Teil 1
-	19.06.2025	Feiertag (Termin entfällt)
7	26.06.2025	Qualitative Methoden: Verstehen des Einzelfalls Teil 2
8	03.07.2025	(Debattierunde +) Forschungsethik und Open Science
9	10.07.2025	Digitale Messmethoden, Ambulatory Assessment und Machine-Learning
10	17.07.2025	Freie Spitze und Fragen

Heutige Themen

Unterteilung, Auswahl und Einsatz von psychologischen Erhebungsmethoden

Gütekriterien

Reaktivität

Take-Aways und Schlüssel-/Fachbegriffe

- Take-Aways
- Literatursuchaufgabe
- Schlüssel-/Fachbegriffe

Unterteilung, Auswahl und Einsatz von psychologischen Erhebungsmethoden

Frage nach der sogenannten **Operationalisierung** (das "messbar Machen" von Merkmalen) von psychologischen Variablen: Wie kann und möchte ich die psychologische Variable abbilden, die mich interessiert?

Variablen in der Psychologie unterscheiden sich in ihrer empirischen Zugänglichkeit:

Manifeste Variablen:

- der Sinneserfahrung direkt zugänglich, direkt beobachtbar
- Beispiele: sichtbares Verhalten, Gesichtsausdruck, Blutdruck, Reaktionszeiten, Inhalt von Aussagen/Antworten, Anzahl gelöster Aufgaben

→ leicht feststellbar, theoretische Bedeutung meist direkt ersichtlich

Latente Variablen = Konstrukte:

- nur indirekt mit Beobachtungssachverhalten in Verbindung zu bringen, nicht direkt beobachtbar
- Beispiele: Persönlichkeit, Intelligenz, Emotion, Depression

→ man schließt von manifesten **Indikatoren** auf das latente Merkmal auf Basis von theoretischen Überlegungen (Annahme: latente Variable beeinflusst den manifesten Indikator)

Was für weitere manifeste oder latente Variablen fallen Ihnen ein?

Was heißt dann „Messen“ in der Psychologie?

- Zuordnung von Zahlen zu Objekten (z.B. Beobachtungsdaten) nach festen Regeln
- In der Relation der Messwerte muss sich die Relation der gemessenen Objekte widerspiegeln (d.h. wenn z.B. A und B hinsichtlich der gemessenen Variablen gleich sind, sollten sie auch dieselben Zahlen erhalten; wenn $A > B$, sollte Zahl für A $>$ Zahl für B sein.)

Beispiel: „Messung“ von Intelligenz

- Intelligenz nicht direkt beobachtbar (latente Variable, Konstrukt)
- Intelligenz wird über Ergebnis in Leistungstests operationalisiert (Indikatoren)

→ von Anzahl gelöster Aufgaben wird auf die "dahinter liegende" Intelligenz geschlossen

- Unterschiedlichen Ausprägungen von Intelligenz werden unterschiedliche Zahlen zugeordnet
- Differenzen zwischen Zahlen sollen Unterschieden zwischen Personen entsprechen

Unterteilung, Auswahl und Einsatz von psychologischen Erhebungsmethoden



Was heißt dann „Messen“ in der Psychologie?

Beispiel: „Messung“ von Angst

- Angst nicht direkt beobachtbar (latente Variable, Konstrukt)
- Verschiedene Theorien zu Bestandteilen der Angst
- Angst wird z.B. erhoben mittels Fragebogen, in dem eine Person sich bzgl. der Prüfungsangst einschätzt. -> Anzahl an Fragen, denen Person zustimmt (JA/ NEIN) oder Ausmaß der Zustimmung
- ODER: man lässt offen erzählen, im Interview
- ODER: man misst in Prüfungssituation physiologische Parameter

Konkrete Operationalisierung hängt immer vom Kontext, den Ressourcen und der zugrundeliegenden Theorie ab

Unterteilung von Erhebungsmethoden

1. Unterscheidung nach Vorgehen bei der Methode:

- Verhaltensbeobachtungsverfahren → siehe Einheit 3
- Verfahren des Selbst- bzw. Fremdbereichs (Fragebögen, Interviews) → siehe Einheit 4
- Psychologische Tests (z.B. Leistungstests) → siehe Einheit 4
- Biopsychologische bzw. neurowissenschaftliche Messungen → siehe Einheit 6
- Computerbasierte Verfahren → siehe Einheit 4
- Implizite Verfahren → siehe Einheit 4
- Dokumentenanalyse → siehe Einheit 7

→ Verfahren sind nicht völlig distinkt, sondern weisen Überschneidungen auf (z.B. gibt es psychologische Tests als computerbasierte Verfahren)

Unterteilung, Auswahl und Einsatz von psychologischen Erhebungsmethoden

Unterteilung von Erhebungsmethoden

2. Unterscheidung nach Art der Daten, die generiert werden:

Quantitative Erhebungsmethoden:

- Erfahrungsrealität wird in Zahlen erfasst bzw. übersetzt
- Ergebnis: primär numerische Daten
- Beispiele: Antworten auf eine Frage mit einer Antwortskala von 1-5, Anzahl gelöster Aufgaben, Amplitudenhöhe bei einer EEG-Messung
- Häufig stark standardisiert
- Dominante Erhebungsmethode in der Psychologie

Qualitative Erhebungsmethoden:

- Erfahrungsrealität wird in Wörtern oder anderen nicht-numerischen Repräsentationen (z.B. Abbildungen) erfasst bzw. übersetzt
- Ergebnis: primär verbale Daten
- Häufig weniger stark bis gar nicht standardisiert
- Beispiele: gesprochene Inhalte, geschriebene Texte, Beobachtungsprotokolle

→ Viele der auf der vorherigen Folie genannten Methoden gibt es in quantitativen und qualitativen Varianten

Unterteilung, Auswahl und Einsatz von psychologischen Erhebungsmethoden

Auswahl und Einsatz von Erhebungsmethoden

Übergeordnete Perspektive


- **Ziel:** wissenschaftliche Fragestellungen in der Psychologie in Breite und Tiefe beantworten
- **Lösung:** Prinzipiell anstreben, Fragestellungen mit mehreren Datenerhebungsverfahren bzw. basierend auf unterschiedlichen Datenquellen zu untersuchen ("**multimodale** Erfassung" oder "**multimethodale** Erfassung")

Perspektive der Einzelstudie

- häufig nicht möglich oder sinnvoll, innerhalb einer einzigen Studie verschiedene Methoden einzusetzen (ökonomische oder versuchsplanerische Gründe)
- konkrete einzelne Untersuchung → gezielte Auswahl weniger Methoden

Gütekriterien von Erhebungsmethoden

- Zur Auswahl und Bewertung psychologischer Erhebungsmethoden müssen Qualitätskriterien berücksichtigt werden.
- Für quantitative Methoden kann man rechtstehende Güterkriterien betrachten.
- Skalierung manchmal auch als Teilaspekt der Validität ("Strukturelle Validität") oder als Nebengütekriterium
- Für Gütekriterien von qualitativen Methoden → siehe Einheit 7



Gütekriterien von Erhebungsmethoden

Objektivität

Definition: Eine Erhebungsmethode ist objektiv, wenn sie das Merkmal unabhängig von Testleiter:in, Testauswerter:in und von Ergebnisinterpretation misst.

3 Bereiche lassen sich unterscheiden:

1. Durchführungsobjektivität (Testleiterunabhängigkeit)
2. Auswertungsobjektivität (Verrechnungssicherheit)
3. Interpretationsobjektivität (Interpretationseindeutigkeit)

Gütekriterien von Erhebungsmethoden

Objektivität

Durchführungsobjektivität

Definition: Testergebnis soll nicht davon abhängen, welche Testleiter:in Test durchführt → Erhebung sollte unter möglichst standardisierten Bedingungen stattfinden, Testperson als einzige Variationsquelle

Kann bei Verhaltensbeobachtung z.B. durch statistische Kennzahlen zur *Beobachtungs*übereinstimmung erfasst werden

Standardisierung wird optimiert durch:

- Instruktionen der Testleiter und Ablauf schriftlich festhalten (z.B. auch durch Interviewleitfäden bei Interviews, oder Beobachtungsplan bei Verhaltensbeobachtung)
- soziale (nicht-testbezogene) Interaktion zwischen Versuchsleiter und Testperson gering halten
- für möglichst ähnliche Untersuchungssituation sorgen (z.B. Einzel vs. Gruppentestung, Zeitbegrenzungen)
- eindeutige Anweisungen für Umgang mit Nachfragen, Störungen im Testablauf
- Bei Verhaltensbeobachtung: Training von Beobachtern

Gütekriterien von Erhebungsmethoden

Objektivität

Auswertungsobjektivität

Definition: Beim Vorliegen der Antworten/Beobachtungen einer Person soll jede Auswerter:in zum selben Ergebnis kommen

Kann z.B. durch statistische Kennzahlen zur *Beurteilungs*übereinstimmung erfasst werden

Auswertungsobjektivität wird optimiert durch:

- Vermeiden freier Antwortformate
- klare Auswertungsregeln
- Hilfsmittel, wie z.B. Auswertungsschablonen oder computergestützte Auswertung
- Festgelegte Ausschlusskriterien
- Informationen zum Umgang mit fehlenden Werten
- Festlegung von Antwortmöglichkeiten z.B. bei Interviews
- Verhaltensverankerte Ratingskalen, z.B. bei Verhaltensbeobachtungen
- Training von Beurteilern

Gütekriterien von Erhebungsmethoden

Objektivität

Interpretationsobjektivität

Definition: Unterschiedliche Erheber:innen sollen beim Vorliegen der Ergebnisse zum selben Schluss kommen.

Interpretationsobjektivität kann erhöht werden durch:

- klare Regeln für die Interpretation, z.B. durch Vorgaben zur Benennung und Beschreibung des erhobenen Merkmals, sowie der Bedeutung seiner Ausprägungen
- Vorhandensein von Normen/Normwerten inkl. Informationen zu den darin verwendeten Stichproben
- Hinweise auf Interpretation auf Basis von Konfidenzintervallen (Vertrauensbereiche, siehe VL Quantitative Methoden) und Klassifikation in Kategorien (z.B. „durchschnittlich“)
- Fallbeispiele

Erhebungsmethoden der psychologischen Forschung

Gütekriterien von Erhebungsmethoden

Objektivität

Steckbrief IDS-2: Intelligence and Development Scales – 2. Intelligenz- und Entwicklungsskalen für Kinder und Jugendliche (Grob und Hagmann-von Arx 2018)	
Zielsetzung und Testkonstruktion	
Messgegenstand	Intelligenz sowie Kompetenzen in 5 entwicklungsrelevanten Funktionsbereichen bei Kindern und Jugendlichen
Anwendungsbereich	Breiter Anwendungsbereich im gesamten Spektrum der Entwicklungs- und Leistungsdiagnostik, der Schuleingangsdiagnostik und im klinischen Bereich
Theoretischer Hintergrund	Theoretische Fundierung der Intelligenz anhand des CHC-Modells (► Abschn. 3.2.4.1), Auswahl der Kompetenzbereiche eher pragmatisch
Testentwicklung	Weiterentwicklung der IDS mit Erweiterung des Altersbereichs; neue Funktionsbereiche „exekutive Funktionen“ und „Arbeitshaltung“, erweiterte Normen
Maßnahmen zur Gewährleistung der Objektivität	
Durchführung	Standardisierte schriftliche und mündliche Instruktion; mit Hinweisen für den Umgang mit Fragen
Auswertung	Detaillierte Bewertungsregeln und die anschließende Auswertung der Rohwerte erfolgt ausschließlich durch ein Auswertungsprogramm
Interpretation	Genaue Vorgaben zur Benennung der erfassten Merkmale und zur Verbalisierung ihrer Ausprägung und Fallbeispiele

Gütekriterien von Erhebungsmethoden

Reliabilität

Definition: Eine Erhebungsmethode ist (vollständig) reliabel (zuverlässig), wenn sie das Merkmal ohne Messfehler misst

- Anders ausgedrückt: Reliabilität gibt den Grad der Genauigkeit an, mit der eine Erhebungsmethode misst
- Formal: Anteil der Varianz der wahren Werte an der Gesamtvarianz der Beobachtungsdaten (siehe Vorlesung Testtheorie)
- Wichtige Einflussgröße auf Breite der Konfidenzintervalle in der Einzelfalldiagnostik (→ wie sicher kann ich mir bei einer einzelnen Messung sein)

Gütekriterien von Erhebungsmethoden

Reliabilität

Es lassen sich verschiedene Arten zur Schätzung der Reliabilität unterscheiden:

- **Retest-Reliabilität** → Erhebungsmethode kommt bei Wiederholung zum selben Ergebnis
- **Paralleltest-Reliabilität** → Erhebungsmethode kommt unter vergleichbaren Bedingungen bzw. vergleichbaren Erhebungsmethoden (z.B. bei Durchführung mit einer Parallelförmigkeit) zum selben Ergebnis
- **Innere Konsistenz** → Einzelteile der Erhebungsmethode (z.B. Items eines Fragebogens) kommen alle zu ähnlichen Ergebnissen
- **Testhalbierungs- (Split Half-)Reliabilität** → analog zur inneren Konsistenz: Trennung der Erhebungsmethode in genau zwei Hälften, und Vergleich der Ergebnisse

Gütekriterien von Erhebungsmethoden

Reliabilität

Reliabilität	
Konsistenz	Hauptkennwert IQ resp. IQ-Profil: $\alpha = .97$ resp. $.98$; IQ-Screening: $\alpha = .95$ Intelligenzfaktoren: $\alpha = .91$ bis $.98$ (jeweils für die Gesamtstichprobe); exekutive Funktionen: $\alpha = .88$ (für die Gesamtstichprobe); allgemeine Entwicklungsfunktionen: $\alpha = .82$ bis $.97$ (für die einzelnen Altersgruppen)
Retest	IQ resp. IQ-Profil: $r = .89$ resp. $.86$; IQ-Screening: $r = .85$; Intelligenzfaktoren: $r = .65$ bis $.89$ (durchschnittlich: 24 Tage, Intervall: 9–63 Tage, $N = 69$)

Gütekriterien von Erhebungsmethoden

Validität

Definition: Eine Erhebungsmethode ist valide, wenn sie das Merkmal, das sie messen soll, auch wirklich misst (und nichts anderes).

Zwei wichtige Aspekte:

Kausale Validität

- Verursache Variation im Merkmal eine Variation im Testwert?
- Bei kausaler Validität geht es nicht um Korrelation (ungerichtete Zusammenhänge), sondern um Kausalität (gerichtete Zusammenhänge)
- Kausale Validität ist das eigentliche Herzstück, wenn man von "Validität" spricht

Inhaltsvalidität

- Erhebungsmethode erfasst repräsentativ alle relevanten Bestandteile des erhobenen Konstrukts
- Beispiel: Depressionsfragebogen sollte alle relevanten Depressionssymptome und keine nicht für Depression relevanten Symptome enthalten

Gütekriterien von Erhebungsmethoden

Validität

Häufig angewandte **Validierungsmöglichkeiten** auf Basis von Korrelationen:

1) Untersuchung der **Konstruktvalidität**

- Erhebungsmethode erzeugt Daten, die mit Daten anderer Erhebungsmethoden zusammenhängen, die dasselbe oder etwas sehr ähnliches messen sollen (**konvergente Validität**)
- Erhebungsmethode erzeugt Daten, die mit Daten anderer Erhebungsmethoden, die *nicht* dasselbe messen sollen, weniger stark zusammenhängen (**divergente/diskriminante Validität**)
- (Teilweise wird hier auch faktorielle Validität verordnet: Erwartungsgemäße statistische Faktorenstruktur des Tests → siehe Vorlesung Testtheorie)

Gütekriterien von Erhebungsmethoden

Validität

- Basis für Erwartungen im Rahmen der Konstruktvalidität sind theoretische Überlegungen, die a priori (vor Kenntnis der empirischen Zusammenhänge) aufgestellt werden sollten
- Mit der sogenannten "**Multitrait-Multimethod-Methode**" können diese a priori Erwartungen systematisiert und entsprechende empirische Belege verordnet werden
- Problem sind Zirkelschlüsse:
 - Test A: „Test A korreliert (erwartungsgemäß) mit Test B, also ist A valide!“
 - Test B: „Test B korreliert (erwartungsgemäß) mit Test A, also ist B valide!“
 - Was wäre denn, wenn Test A und Test B beide etwas völlig anderes messen würden? (Intelligenz vs. Arbeitsgedächtnis)

Tab. 2.21 Multitrait-Multimethod-Matrix

		Methode 1			Methode 2			Methode 3		
		Trait 1	Trait 2	Trait 3	Trait 1	Trait 2	Trait 3	Trait 1	Trait 2	Trait 3
Methode 1	Trait 1	(Rel.)								
	Trait 2		(Rel.)							
	Trait 3			(Rel.)						
Methode 2	Trait 1				(Rel.)					
	Trait 2					(Rel.)				
	Trait 3						(Rel.)			
Methode 3	Trait 1							(Rel.)		
	Trait 2								(Rel.)	
	Trait 3									(Rel.)

Anmerkungen.
»Reliabilitätsdiagonale«: In der Hauptdiagonalen stehen die Reliabilitäten (Rel.) der Verfahren.
Graue Felder = »Validitätsdiagonalen« (»monotrait-heteromethod«): Ein Merkmal wird mit verschiedenen Methoden gemessen.
Blaue Felder = »Heterotrait-Monomethod-Dreiecke«: Verschiedene Merkmale werden mit der gleichen Methode erfasst.
Alle weißen Felder unter der Reliabilitätsdiagonalen = »Heterotrait-Heteromethod-Dreiecke«: Korrelation zwischen verschiedenen Merkmalen, die zudem mit unterschiedlichen Methoden gemessen wurden.
Die Felder über der Hauptdiagonalen bleiben leer.

Gütekriterien von Erhebungsmethoden

Validität

Häufig angewandte **Validierungsmöglichkeiten** auf Basis von Korrelationen:

2) Untersuchung der **Kriteriumsvalidität**

- Erhebungsmethode erzeugt Daten, die mit relevanten, konkreten, externen Kriterien (außerhalb der unmittelbaren Testsituation) in Zusammenhang stehen (z.B. Intelligenztest mit Kriterien für Berufungserfolg, z.B. Gehalt, Karrierestufe, Abschluss)
- Auch Untersuchung über **(Extrem) -gruppenvergleiche**, die erwartungsmäße Muster zeigen, d.h. Studien zu Mittelwertsunterschieden zwischen Gruppen bei denen ein Unterschied erwartet wird (z.B. Test der Einstellung gegenüber der Kirche misst sollte bei Kirchengängern höher ausfallen als bei Nicht-Kirchengängern)
- **Inkrementelle (Kriteriums-)validität**: Beitrag einer Erhebungsmethode zur Verbesserung der Vorhersage eines Kriteriums über andere Erhebungsmethoden hinaus

Erhebungsmethoden der psychologischen Forschung

Gütekriterien von Erhebungsmethoden

Validität

■ Tab. 2.19 Beispiele für Kriterien zur Validierung von Tests

Diagnostisches Verfahren (Verwendungszweck)	Mögliches Kriterium	Begründung
Depressionsfragebogen (soll Schwere der Depression erfassen)	Dauer des Aufenthaltes in einer psychiatrischen Klinik	Je schwerer die Störung, desto länger sollte die Behandlung im Krankenhaus dauern.
Intelligenztest (soll Schulerfolg vorhersagen)	Abiturnote drei Jahre nach Testdurchführung	Die Abiturnote ist ein aner- kanntes Maß für Schulerfolg; da prognostische Validität ange- strebt wird, muss das Kriterium deutlich später erhoben werden.
Aufmerksamkeitstest (soll Fahreignung erfassen)	Fehler in einer standar- disierten Fahrprobe	Aufmerksamkeitsdefizite sollten sich in bestimmten Fehlern wie Übersehen von Verkehrszeichen, Gefahren oder der Geschwindig- keitsanzeige im Auto nieder- schlagen. Das Verhalten sollte im Straßenverkehr erfasst werden, weil der Test für diesen Bereich eingesetzt wird.

Gütekriterien von Erhebungsmethoden

Validität

DOI: 10.1111/nyas.15081

ORIGINAL ARTICLE

ANNALS OF THE NEW YORK
ACADEMY OF SCIENCES

How accurate are self-evaluations of singing ability?

Daniel Yeom^{1,†} | Kendall S. Stead^{1,2,†} | Yi Ting Tan³ | Gary E. McPherson³ | Sarah J. Wilson^{1,4}

¹Melbourne School of Psychological Sciences, University of Melbourne, Melbourne, Victoria, Australia

²School of Psychological Sciences, Macquarie University, Sydney, New South Wales, Australia

³Melbourne Conservatorium of Music, University of Melbourne, Melbourne, Victoria, Australia

⁴Department of Medicine, Epilepsy Research Centre, University of Melbourne, Austin Health, Heidelberg, Victoria, Australia

Correspondence

Sarah J. Wilson, Melbourne School of Psychological Sciences, University of Melbourne, Redmond Barry Building, Parkville, VIC 3010, Australia. Email: sarahw@unimelb.edu.au

[†]These authors contributed to the work equally and share first-author status.

Funding information

Australian Government Research Training Program Scholarship; Australian Research Council, Grant/Award Numbers: DP170102479, DP200100961

Abstract

Research has shown that people inaccurately assess their own abilities on self-report measures, including academic, athletic, and music ability. Evidence suggests this is also true for singing, with individuals either overestimating or underestimating their level of singing competency. In this paper, we present the **Melbourne Singing Tool Questionnaire (MST-Q)**, a brief 16-item measure exploring people's self-perceptions of singing ability and engagement with singing. Using a large sample of Australian twins ($n = 996$), we identified three latent factors underlying MST-Q items and examined whether these factors were related to an objective phenotypic measure of singing ability. The three factors were identified as Personal Engagement, Social Engagement, and Self-Evaluation. All factors were positively associated with objective singing performance, with the Self-Evaluation factor yielding the strongest correlation ($r = 0.66$). Both the Self-Evaluation factor and a single self-report item of singing ability shared the same predictive strength. Contrary to expectations, our findings suggest that self-evaluation strongly predicts singing ability, and this self-evaluation is of higher predictive value than self-reported engagement with music and singing.

KEYWORDS

self-assessment, self-report, singing, singing engagement, singing questionnaire


Gütekriterien von Erhebungsmethoden

Reliabilität

Validität	
Konstruktvalidität	Überprüfung der Faktorenstruktur der Intelligenzwerte IQ und IQ-Profil durch konfirmatorische Faktorenanalysen ($N=1672$); einige Studien zur Korrelation der IDS-2 mit anderen Intelligenztests (u. a. IDS-2 IQ/IQ-Profil mit Kennwerten der Gesamtintelligenz in Referenztests WISC-IV, Reynolds Intellectual Assessment Scales and Screening [RIAS], Non-verbaler Intelligenztest [SON-R 6–40]): $r = .51$ bis $.69$
Kriteriumsvalidität	Für den Funktionsbereich „schulische Kompetenzen“ Analyse der Schulleistungen durch Elterneinschätzungen und Schulnoten

Gütekriterien von Erhebungsmethoden

Veranschaulichung unterschiedlicher Reliabilität und Validität



Gütekriterien von Erhebungsmethoden

Skalierung

Bei der Skalierung geht es um die **statistische Modellierung von Messprozessen**: Ein psychologischer Test gilt als skalierbar, wenn die Zuordnung der Messwerte zu den Personen auf der Basis eines empirisch nachgewiesenen testtheoretischen Modells geschieht.

Zwei Aspekte:

- Empirischer "Nachweis", dass ein bestimmtes testtheoretisches Modell gilt, also das "Richtige" ist
- Auf der Basis des "nachgewiesenen" testtheoretischen Modells Personen Werte auf den latenten Variablen zuweisen (und nicht irgendwie anders)

Die meisten psychologischen Fragebögenskalen und Tests basieren auf der klassischen Testtheorie (daher werden Sie dazu bereits im Bachelor eine eigene Vorlesung hören)

Gütekriterien von Erhebungsmethoden

Skalierung

Klassische Testtheorie (KTT):

- Anwendung auf Ratingskalen möglich (aber eigentlich für stetige Variablen entwickelt, z.B. Reaktionszeiten)
- Zentrale Annahme: Jeder Testwert einer Person auf einem konkreten Item (z.B. einer Frage) ist aus zwei Komponenten zusammengesetzt:

1. Wahrer Wert:

- mittlerer Testwert, den eine Person in einer unendlichen Serie von Testwiederholungen erzielen würde (Erwartungswert)
- keine praktisch erzielbare, sondern eine theoretische Größe
- kann aber durch die konkrete empirische Antwort einer Person geschätzt werden
- Es existieren verschiedene testtheoretische Modelle je nach Annahme wie sich die Items in Hinblick auf die Messung der latenten Variable unterscheiden

2. Fehleranteil (Messfehler):

- Abweichung dieses empirischen Schätzwerts vom wahren Wert
- z.B. Störeinflüsse der Umwelt

Gütekriterien von Erhebungsmethoden

Skalierung

Klassische Testtheorie (KTT):

- **Ziel:** möglichst direkte und präzise Schätzung des wahren Werts auf einem Item, um darauf basierend einen Rückschluss auf eine latente Variable machen zu können
- **Verbreitetste Analysemethode zur Überprüfung: Faktorenanalyse**
- Die KTT stellt verschiedene Axiome (definitorische Festlegungen/Annahmen) auf, darunter die Annahme, dass der mittlere Messfehler gleich null ist. Bei wiederholten Testanwendungen gleichen sich die verschiedenen Messfehler sozusagen aus

→ **mit Messfehler werden in der KTT damit nur unsystematische Messfehler gemeint/berücksichtigt. Es kann jedoch auch systematische Messfehler geben...**

- Durch den Einsatz mehrerer Testitems in einem Fragebogen soll der Fehleranteil insgesamt minimiert werden, oder anders ausgedrückt: Mehrere Items ermöglichen eine bessere Annäherung an die latente Variable einer Person

Gütekriterien von Erhebungsmethoden

Skalierung

Unsystematische Messfehler

- zufällige Fehler
- Beispiel: vorübergehende, nicht systematisch auftretende Unaufmerksamkeit, die bei einem Mal zu einer höheren und beim anderen Mal zu einer niedrigeren Itemantwort führt

Systematische Messfehler


- spezifische Situations- oder Persönlichkeitseffekte, die die Antworten systematisch in eine bestimmte Richtung verzerren
- Beispiele: extremer Antwortstil, sozial erwünschte Antworten, mangelnde Motivation bei der Bearbeitung des Tests, Methodeneffekte...

Gütekriterien von Erhebungsmethoden

Skalierung

Beispiel für eine Anwendung der KTT: Selbstwert, Messung über **Multidimensionale Selbstwertkala (MSWS)**

- Erfassung der Selbstwertschätzung von Erwachsenen durch einen Selbstbeschreibungsfragebogen
- Mehr-Facettenmodell: es werden verschiedene Bereiche der Selbstwertschätzung unterschieden
- 32 Items, 6 Subskalen, 1 Gesamtwert



Erhebungsmethoden der psychologischen Forschung

Gütekriterien von Erhebungsmethoden

Skalierung

Abkürzung	Bezeichnung	Zusammensetzung	Beispielitems
ESWS	Emotionale Selbstwertschätzung	1-, 2-, 3, 16-, 17-, 18-, 19	Zweifeln Sie an sich selbst?
SWKO	Soziale Selbstwertschätzung - Sicherheit im Kontakt	4-, 5-, 20-, 21-, 22-	Wie häufig fühlen Sie sich gehemmt?
SWKR	Soziale Selbstwertschätzung - Umgang mit Kritik	6-, 7-, 23-, 24-, 25-	Wie sehr machen Sie sich Gedanken darüber, ob andere Leute Sie als Versager sehen?
LSWS	Leistungsbezogene Selbstwertschätzung	8, 9-, 26, 27, 28-	Zweifeln Sie an Ihren fachlichen Fähigkeiten?
SWPA	Selbstwertschätzung Physische Attraktivität	10-, 11, 29-, 30-, 31	Wie sicher sind Sie, dass Sie für gutaussehend gehalten werden?
SWSP	Selbstwertschätzung Sportlichkeit	12-, 13, 14-, 15, 32-	Wie häufig haben Sie schon das Gefühl gehabt, dass anderen Ihnen sportlich überlegen sind?
ASW	Allgemeine Selbstwertschätzung	ESWS, SWKO, SWKR, LSWS	
KSW	Körperbezogene Selbstwertschätzung	SWPA, SWSP	
GSW	Gesamtselbstwert	ASW, KSW	

Gütekriterien von Erhebungsmethoden

Skalierung

Frage: Wie haben die Autor:innen entschieden, dass gerade diese Fragen sich zur Messung der 6 Subskalen eignen? Es könnte ja auch sein, dass Item 1 eigentlich Soziale Selbstwertschätzung misst...

Antwort: Statistisches Verfahren der **Faktorenanalyse** basierend auf der KTT

- Prüft sogenannte Ladungen der Einzelitems auf einen latenten Faktor (wie stark hängt das Item mit einem Faktor zusammen)
- So können einzelne Fragen in unterschiedliche Subskalen **sortiert** werden
- Anzahl und Zusammensetzung der Subskalen nennt man **Faktorstruktur** eines Fragebogens
- Fragebogen ohne Subskalen nennt man **eindimensional** mit mehrere Subskalen **mehrdimensional**
- Inhaltliche Bezeichnung der Subskalen/Faktoren nehmen die Autoren anhand der Items vor, die auf sie laden (z.B. Frage zu Aussehen und Frage zu Attraktivität laden auf selben Faktor --- Also nennen wir ihn "Selbstwertschätzung Physische Attraktivität")

Gütekriterien von Erhebungsmethoden

Skalierung

Zusammenfassung: Klassische Testtheorie:

- Schätzung des wahren Werts unter Berücksichtigung des (unsystematischen) Messfehlers
- Es existieren verschiedene testtheoretische Modelle je nach Annahme wie sich die Items in Hinblick auf die Messung der latenten Variable unterscheiden

Ausblick: Probabilistische Testtheorie aka. Item-Response-Theorie (IRT, Embretson & Reise, 2000; Rasch, 1980)

- Schätzung der Wahrscheinlichkeit, mit der eine Person mit einer bestimmten Merkmalsausprägung ein Item auf eine bestimmte Art beantwortet (bzw. ein Item löst)
- Es existieren verschiedene testtheoretische Modelle je nach Skalenniveau der Antworten (d.h. auch für dichotome Antworten einsetzbar, z.B. ja/nein, richtig/falsch)
- Detailliertere Abbildung des Antwortprozesses möglich als bei der KTT (z.B. Berücksichtigung von Ratewahrscheinlichkeiten)
- Ausführliche Behandlung im Masterstudium

Gütekriterien von Erhebungsmethoden

Nebengütekriterien


- **Normierung:** Bezugssystem vorhanden, auf Basis aktueller, repräsentativer und großer Stichprobe, um die individuellen Testwerte vergleichend einordnen zu können
- **Vergleichbarkeit:** Parallelfarm bzw. andere Verfahren mit gleichem Gültigkeitsbereich vorhanden
- **Ökonomie:** Verfahren ist kurz, einfach in der Handhabung, für Gruppenuntersuchung geeignet, wenig materialintensiv und schnell auswertbar (Verhältnis von Kosten und Nutzen im Vergleich zu anderen Verfahren relevant)
- **Zumutbarkeit:** Schonung der untersuchten Personen in zeitlicher, psychischer und körperlicher Hinsicht
- **Fairness:** Einzelne Gruppen werden durch die erhaltenen Ergebnisse eines Verfahrens nicht diskriminiert, d.h. nicht aufgrund einer testirrelevanten Eigenschaft systematisch benachteiligt
- **Nicht-Verfälschbarkeit:** keine willentliche Beeinflussung der Testleitung zum Erlangen eines ungerechtfertigten Vorteils
- **Nutzen** (wird nicht immer aufgeführt): Erfüllung eines praktischen Bedürfnisses durch den Test (der nicht schon besser durch andere Verfahren abgedeckt ist)

Problem der Reaktivität

Definition: Veränderung/Verzerrung der erhobenen Daten aufgrund der Kenntnis der untersuchten Person darüber, dass sie Gegenstand einer Untersuchung ist → Reaktivität ist häufig ein systematischer Messfehler

Mögliche Ursachen:

- Veränderte Aufmerksamkeitslenkung
- Relevanz sozialer Erwünschtheit (Selbstdarstellerisches, sozial konformes (Antwort-)Verhalten)
- Aufforderungscharakteristika der Untersuchungssituation (**demand effects**)



→ Datenerhebungen in Psychologie verändern oft bereits den Gegenstand



Beispiel: Hawthorne-Effekt

- klassische Studie in den Hawthorne-Werken der Western Electric Company (Roethlisberger und Dickson, 1939)
- Aussage: bloße wissenschaftliche Untersuchung der Arbeiter:innen führte zu Steigerung der Produktivität, Produktivitätssteigerung war **unabhängig** von den durch die Forscher implementierten Veränderungen der Arbeitsbedingungen
- Es folgte methodische Kritik an dieser Studie (z.B. Adair, 1984; Jones, 1992)
- Trotzdem: Mögliche Bewertungserwartung der untersuchten Personen bekam dadurch Aufmerksamkeit



Problem der Reaktivität

Einschätzung des Ausmaßes der Reaktivität bzw. Nichtreaktivität abhängig von Informationslage der Versuchspersonen (Vpn)

Setting vom Forschenden für die Untersuchung geschaffen/ausgewählt?	ja	ja	ja	ja	ja	nein
Sind sich die Vpn des Forschungssettings bewusst?	ja	ja	ja	ja	nein	nein
Kennen die Vpn das Forschungsthema?	ja	ja	ja	nein	nein	nein
Sind sich die Vpn der Hypothese bewusst?	ja	ja	nein	nein	nein	nein
Sind sich die Vpn der Manipulierbarkeit der Erhebung bewusst?	ja	nein	nein	nein	nein	nein
Typ (Nichtreaktivität):	0	1	2	3	4	5

Beispiel für Typ 4: "Lost-Letter-Technique", bei der Briefe frankiert an öffentlichen Orten fallen gelassen werden, und geprüft (und dadurch zeitversetzt "beobachtet" wird), ob sie abgesendet werden (Milgram, Mann & Harter, 1965)

Beispiel für Typ 5: Spontane Nähe-vs. Distanzregulation im Hörsaal (Campbell, Kruskal & Wallace, 1966) oder in einer Cafeteria (Clack, Dixon & Tredoux, 2005)

Maßnahmen zur Reduktion von Reaktivität

Maßnahme	Bewertung
Versuchspersonen in Unkenntnis darüber lassen, dass sie untersucht werden	Nur in Feld-, Archiv- oder Internetstudien praktikabel, nicht in Laborstudien; kann ethisch problematisch sein
Versuchspersonen Anonymität zusichern	Besonders wichtig bei der Erhebung von persönlichen/sensiblen Daten; reduziert sozial-erwünschtes Antworten
Coverstory über den Untersuchungszweck entwickeln	Wichtig in hypothesenprüfenden Studien, in denen die Versuchspersonen erforschtes Verhalten kontrollieren können; Täuschung ethisch zu reflektieren
Maße einsetzen, die von Versuchspersonen nicht kontrolliert oder beeinflusst werden können (nicht-reaktive Messverfahren)	Angenommen für biopsychologische Maße, die kaum kontrollierbare physiologische Vorgänge erfassen (z.B. Messung von Hormonspiegeln oder Verfahren zur Messung der Gehirnaktivität)
Indirekte/implizite Messverfahren einsetzen	Versuchspersonen können aus gemessenen Verhaltensweisen (oft Reaktionszeiten) nur schwer auf das untersuchte Konstrukt schließen

Warum ist das für mich wichtig?

"Methoden, mit denen die Psychologie ihre Daten gewinnt und auswertet, gehören zu den **»Regeln der Kunst«**, auf die uns die **ethischen Richtlinien unserer Profession** verpflichten (Deutsche Gesellschaft für Psychologie und Berufsverband Deutscher Psychologinnen und Psychologen, 2005).

*Es ist ein verbreitetes Missverständnis, dass gute Methodenkenntnisse nur in der psychologischen Forschung benötigt werden. **Auch in der psychologischen Anwendungspraxis ist gutes Methodenwissen unverzichtbar.** Nur wer über dieses Wissen verfügt, ist beispielsweise in der Lage, die wissenschaftliche Literatur kritisch zu beurteilen, zu entscheiden, welches diagnostische Verfahren welche Gütekriterien wie gut erfüllt und wie die psychologische Praxis zur Generierung von Wissen und somit für den wissenschaftlichen Fortschritt genutzt werden kann.*

*Da mit Psychologie auch Geld verdient wird, gibt es ein Spannungsverhältnis zwischen dem wirtschaftlichem Gewinn und der wissenschaftlichen Qualität einer psychologischen Dienstleistung. **Nur wer über methodisches Wissen verfügt, kann psychologische Dienstleistungsangebote in diesem Spannungsverhältnis verorten und unseriöse Angebote von seriösen unterscheiden.***

(Eid, Gollwitzer & Schmitt, S.37)

- **Hauptgütekriterien** für psychologische Erhebungen sind Objektivität, Reliabilität und Validität (je nach Autor auch Skalierung)
- **Objektivität:** Erhebung, Ergebnis und Interpretation unabhängig von Testleiter:in und Testauswerter:in
- **Reliabilität:** Messfehlerfreie und zuverlässige Erhebung des Merkmals
- **Validität:** Methode erhebt wirklich das interessierende Merkmal und nicht etwas anderes
- **Klassische Testtheorie:** Schätzung des wahren Werts unter Berücksichtigung des Messfehlers
- **Probabilistischen Testtheorie:** Schätzung der Wahrscheinlichkeit für eine bestimmte Itemantwort
- **Reaktivität:** Veränderung/Verzerrung der erhobenen Daten aufgrund der Kenntnis der untersuchten Person darüber, dass sie Gegenstand einer Untersuchung ist

Schlüssel-/Fachbegriffe der heutigen Vorlesung

Operationalisierung

manifest

latent

Indikator

Konstrukt

quantitative

qualitativ

multimodal /
multimethodal

Gütekriterien

Objektivität

Reliabilität

Validität

Skalierung

unsystematische
Messfehler

systematische Messfehler

Durchführungsobjektivität

Auswertungsobjektivität

Interpretationsobjektivität

Retest-Reliabilität

Paralleltest-Reliabilität

Innere Konsistenz

Testhalbierungs-Reliabilität
/ Split-Half-Reliabilität

Kausale Validität

Inhaltsvalidität

konvergente / divergente
Konstruktvalidität

Kriteriumsvalidität

Multitrait-Multimethod-
Methode

Reaktivität

demand effects



[zurück zur heutigen Übersicht der Vorlesung →](#)
[zum Quiz zur Wissensprüfung →](#)

Literaturaufgabe



- Das Diagnostik- und Testkuratorium (<https://psyndex.de/tests/testkuratorium/>) wird vom Berufsverband Deutscher Psychologinnen und Psychologen (BDP) und von der Deutschen Gesellschaft für Psychologie (DGPs) getragen.
- Die Hauptaufgabe besteht darin, die Öffentlichkeit vor unzulänglichen psychodiagnostischen Verfahren und unqualifizierter Anwendung solcher Verfahren zu schützen. In Zuge dieser Aufgabe veröffentlicht es regelmäßig Beurteilungen von Testverfahren nach dem TBS-TK – Testbeurteilungssystem des Testkuratoriums - das kann man sich als eine Art Stiftung Warentest für psychologische Testverfahren vorstellen.
- Bitte laden Sie sich aus dem Verzeichnis bisheriger TBS-TK-Rezensionen eine Rezension Ihrer Wahl herunter und lesen Sie sie durch. Schreiben Sie einen jeweils positiven und einen jeweils negativen Aspekt heraus, der bei Objektivität, Zuverlässigkeit oder Gültigkeit (Validität) genannt wird.
- Geben Sie Ihre Ergebnisse im [studynet im Ordner "Einheit 2"](#) unter "Literatur-Aufgabe" ab.

Literatur für die heutige Sitzung



Kapitel 8 in Bühner, M. (2021). Einführung in die Test- und Fragebogenkonstruktion. Pearson.

Kapitel 2.2.1. in Schmidt-Atzert, L., Krumm, S. & Amelang, M. (2021). Psychologische Diagnostik. Springer.

Materialien: Vielen Dank an Prof. Dr. Stephan Goerigk, Prof. Dr. Mario Gollwitzer und den Lehrstuhl für Psychologische Methodenlehre und Diagnostik an der LMU für Bereitstellung der Grundlage für die Materialien