

Einführung in die Forschungsmethoden der Psychologie und Psychotherapie

Einheit 9: Digitale Datenerhebung, Big Data und Machine-Learning

22.01.2024 | Prof. Dr. Caroline Zygar-Hoffmann

Heutige Themen

Digitale Datenerhebung

Ambulatory Assessment & Ecological Momentary Interventions

Big Data und Machine-Learning

Take-Aways und Schlüssel-/Fachbegriffe

- Take-Aways
- Schlüssel-/Fachbegriffe

Digitalisierung traditioneller Datenerhebungsmethoden

- Fragebögen und Tests wurden früher im Paper Pencil Format vorgegeben
- Mittlerweile ist die digitale Form vorherrschend


Methode: Surveytools

- Digitalisierung der Messinstrumente durch die Forscher:innen
- Forschungsmethodische Aspekte (z.B. Randomisierungslogik) wird miteinbezogen (programmiert)
- Ausfüllen durch Proband:innen am Computer/Smartphone
- Nach Ende der Datenerhebung → direkter Export der Daten ins digitale Format

→ Erstellen digitaler Umfragen wird im Modul Empirisch-wissenschaftliches Arbeiten gelernt (2. Semester)

Digitalisierung traditioneller Datenerhebungsmethoden

Surveytools - Beispiel Unipark:



Neue Frage

Fragetitel  Einstellungen zum Fernsehen Filter Ansicht Statisch Dynamisch

Kategorie	Frageart	Icon
Text und Multimedia	Standard-Matrix 1	
	Standard-Matrix 2	
Einfachauswahl	Semantisches Differential	
	Drop-Down-Matrix	
Mehrfachauswahl	Checkbox-Matrix	
	Textfeld-Matrix	
Felder für Texteingabe	Akkordeon-Matrix	
	Karussell	
Matrix	Hotspot	
	Vorschläge	
Schieberegler		
Ranking - Rating		
Erweitert		

Die barrierefreie Fragetypen sind farblich gekennzeichnet (grün).

Hier platzieren Sie den Text für Ihre Frage.
Hier erläutern Sie, wie die Frage ausgefüllt werden soll (optional).

	Skala 1	Skala 2	Skala 3
Dimension 1			
Dimension 2			
Dimension 3			

Abbrechen Speichern Speichern und bearbeiten

→ recht benutzerfreundlich, aber kostenpflichtig

Digitalisierung traditioneller Datenerhebungsmethoden

Surveytools - Beispiel formR:

Notes	class	type	opti	name	showif	label	choice1	choice2
	mc_width80 space_bottom_5	mc_heading mc_aut		AntwortSkala_AutonomieSkala				
	mc_width80	rating_button 1,5,1		Item1_AutonomieSkala		In unserer Partnerschaft kann ich ohne größere Einschränkungen machen, was ich will.		
	mc_width80	rating_button 1,5,1 submit		Item2_AutonomieSkala submit4		In unserer Partnerschaft kann ich meinen eigenen Interessen nachgehen, ohne dass mein Partner sauer ist. Weiter		
Rückmeldungsfrage	left500	note mc		rueckmeldung mc_rueckmeldung		### <center> Rückmeldung </center> Möchten Sie eine Rückmeldung zu Ihren eigenen Daten erhalten?	ja	nein

list_name	name	label
	1	1 __ __ Trifft überhaupt nicht zu __
mc_aut	2	2 __
	3	3 __
	4	4 __
		__ Trifft voll und ganz zu __
	5	5 __

→ Surveys werden über Exceltabelle konfiguriert, mächtig und dadurch sehr flexibel, versteht R Befehle, kostenfrei

Möglichkeiten und Vorteile digitaler Datenerhebung

Möglichkeit Daten unabhängig von der physischen Distanz zwischen den Forschungseinrichtungen und den Teilnehmer:innen zu erheben

Beispiele für Vorteile sind:

- Zeitökonomie
- Keine Übertragungsfehler von Papier in den Computer
- Direkter Export der Antworten ins Datensatzformat, d.h. Analyse kann direkt starten
- Wegfall von kopräsender Versuchsleitung und Versuchsleitereffekten
- ggf. Verringerung des Reaktivitätsproblems
- größere Stichprobengrößen erreichbar und damit höhere Teststärke
- Diversifizierung der Stichproben indem internetbasiert rekrutiert wird
- Erreichbarkeit von Stichproben mit hochspezifischen Merkmalen

Nachteile digitaler Datenerhebung

Digitale Datenerhebung bietet der psychologischen Forschung nicht nur Möglichkeiten und Vorzüge, sondern ist auch mit Risiken und potenziellen Nachteilen behaftet.

Beispiele für Nachteile sind:

- Verringerung der Repräsentativität der Stichproben hinsichtlich Technologieaffinität
- Erschwerte Kontrolle über die Bedingungen der Datenerhebung (z.B. die Einhaltung von Instruktionen, Einhalten der Datenqualität)
- Erschwerter Schutz der Teilnehmenden
- Erschwerte Überprüfung des Verständnisses wichtiger Informationen
- Erschwerte Prüfung der Identifizierbarkeit
- erschwerter Datenschutz und erschwerte informierte Einwilligung

Was ist Ambulatory Assessment?

- **Wiederholte Erfassung** der aktuellen Gedanken, Emotionen, Verhaltensweisen, physiologischen Zustände und des Kontexts von Menschen **in ihrer natürlichen Umgebung** und möglichst im Moment in dem sie auftreten ("Real-time Data Capturing" bzw. "Real-time Monitoring")
- Typischerweise (aber nicht notwendigerweise) über elektronische tragbare Geräte
- Der Begriff "Ambulatory Assessment" (Ebner-Priemer & Trull, 2009) umfasst eine Reihe methodischer Ansätze
 - "Experience Sampling Method" (ESM, Larson & Csikszentmihalyi, 1983), auch "Ecological Momentary Assessment" (EMA, Shiffmann et al., 2008) → mehrmals tägliche Erfassung (meist Selbst-/Fremdauskunft)
 - "Daily Diaries" (Gunthert & Wenze, 2012) → tägliche Abendbefragung ("Tagebuch", meist Selbst-/Fremdauskunft)
 - "Mobile Sensing" → Erhebung der Smartphone/Wearable Nutzungs- und Sensordaten
 - "Ambient Sensing" → Erhebung von in der Umgebung eingebauter Sensordaten
- Die verschiedenen Begriffe betonen unterschiedliche Aspekte der Forschung (z.B. was wird erfasst, wie und wie oft wird erfasst) und werden auch in verschiedenen Subdisziplinen häufiger oder weniger häufig genutzt

Ambulatory Assessment & Ecological Momentary Interventions

Mobile Sensing Studie im entwicklungspsychologischen Bereich

PNAS

RESEARCH ARTICLE

PSYCHOLOGICAL AND COGNITIVE SCIENCES



Everyday language input and production in 1,001 children from six continents

Elika Bergelson^{a,1}, Melanie Soderstrom^b, Iris-Corinna Schwarz^{c,d}, Caroline F. Rowland^{e,f,g}, Nairán Ramírez-Esparza^h, Lisa R. Hamrickⁱ, Ellen Marklund^j, Marina Kalashnikova^k, Ava Guez^l, Marisa Casillas^{a,m}, Lucia Benettiⁿ, Petra van Alphen^o, and Alejandrina Cristia^{a,1}

Edited by Jenny Saffran, University of Wisconsin, Madison, WI; received January 20, 2023; accepted October 14, 2023, by Editorial Board Member Susan A. Gelman

Language is a universal human ability, acquired readily by young children, who otherwise struggle with many basics of survival. And yet, language ability is variable across individuals. Naturalistic and experimental observations suggest that children's linguistic skills vary with factors like socioeconomic status and children's gender. But which factors really influence children's day-to-day language use? Here, we leverage speech technology in a big-data approach to report on a unique cross-cultural and diverse data set: >2,500 d-long, child-centered audio-recordings of 1,001 2- to 48-mo-olds from 12 countries spanning six continents across urban, farmer-forager, and subsistence-farming contexts. As expected, age and language-relevant clinical risks and diagnoses predicted how much speech (and speech-like vocalization) children produced. Critically, so too did adult talk in children's environments: Children who heard more talk from adults produced more speech. In contrast to previous conclusions based on more limited sampling methods and a different set of language proxies, socioeconomic status (operationalized as maternal education) was not significantly associated with children's productions over the first 4 y of life, and neither were gender or multilingualism. These findings from large-scale naturalistic data advance our understanding of which factors are robust predictors of variability in the speech behaviors of young learners in a wide range of everyday contexts.

human diversity | language | socioeconomic status | speech | infancy

Significance

Harnessing a global sample of >40,000 h of child-centered audio capturing young children's home environment, we measured contributors to how much speech 0- to 4-y-olds naturally produce. Amount of adult talk, age, and normative development were the sole significant predictors; child gender, socioeconomic status, and multilingualism did not explain how often children vocalized or how much adult talk they heard. These findings (strengthened by our validation of existing automated speech algorithms) open up interesting

ESM/EMA Sampling Pläne

ESM/EMA kann zwei unterschiedlichen Messregimen folgen:

1) **Time-contingent sampling** bzw. **Signal-contingent sampling**

Teilnehmer antworten auf Fragen zu einem bestimmten Zeitpunkt, wenn sie durch ein Signal dazu aufgefordert werden ("Beeps")

- **Fixed scheme:** Teilnehmer werden zu festen Zeitpunkten aufgefordert, z. B. um 9:30 und 16:30 Uhr → für die Versuchspersonen vorhersehbar, höhere Antwortquote, aber auch höhere **Reaktivität** durch Verhaltensanpassung kurz vor erwarteter Befragung
- **Random scheme:** Aufforderungen werden zu zufälligen Zeitpunkten gesendet, aber i.d.R. in vorher festgelegten Intervallen → bessere Abdeckung des gesamten Alltags, ggf. geringere Reaktivität, aber auch geringere Antwortquote

ESM/EMA Sampling Pläne

ESM/EMA kann zwei unterschiedlichen Messregimen folgen:

2) Event-contingent sampling

Teilnehmer antworten auf Fragen, wenn ein bestimmtes Ereignis eintritt, z.B. eine Panikattacke oder Alkoholkonsum

- Möglichkeit 1: Teilnehmer bitten, Fragebogen selbst zu starten sobald das Ereignis eintritt
- Möglichkeit 2: Kombination ESM/EMA mit Sensing:
 - z.B. Stellen der Frage, wenn bestimmtes Aktivitätslevel überstiegen wird
 - z.B. Stellen der Frage, wenn bestimmte GPS Location erreicht wird

Ambulatory Assessment & Ecological Momentary Interventions

ESM/EMA: Beispiele

←

Wunsch: Interessen

i

←

To-Do-Liste

i

←

Situationen

i

Wünschen Sie sich jetzt gerade:
Alleine Ihren eigenen Interessen nachzugehen?
z.B. ein eigenes Hobby auszuüben; an einem
eigenen Projekt weiterzuarbeiten.

ja, sehr stark
ja, stark
ja, mittelmäßig
ja, aber nur schwach
nein, danach habe ich gerade kein Bedürfnis
nein, das würde mich gerade stören

Wie viel Arbeit wartet in den *nächsten zwei*
Stunden auf Sie (sowohl beruflich, als auch
privat)?

gar keine

sehr viel

Seit heute morgen:
Sind eine oder mehrere der folgenden
Situationen mit Ihrem Partner aufgetreten?

☐

Neutrale Aktivität, Unterhaltung oder Diskussion

☐

Vertraute oder herzliche Aktivität, Unterhaltung
oder Diskussion

☐

Schwache Streitigkeit oder angespannte
Meinungsverschiedenheit / Unstimmigkeit

☐

Stärkerer Streit oder Konflikt

☐


Liebevolle Versöhnung

☐

Keine dieser Situationen ist aufgetreten

ESM/EMA: Beispiele

Multi-dimensionale Stimmungsmessung



Zirkumplexmodell des Affekts (Russell, 1980; Russell et al. 1989)

- Alle Stimmungszustände sind lineare Kombination aus zwei unabhängigen, bipolaren Skalen:
 - Valenz (von unangenehm bis angenehm)
 - Erregung/Aktivierung (von niedriger bis hoher Erregung).
- Kombination ordnet die affektiven Zustände auf einem von vier Quadranten an (`\rightarrow`) Messung über ein "Affect Grid" (Bild links)
- Nachteil: Konzepte von Valenz und Erregung können den Befragten schwer zu vermitteln sein

ESM/EMA: Erfahrungen zu Anwendung im klinischen Kontext

To Use or Not to Use: Exploring Therapists' Experiences with Pre-Treatment EMA-Based Personalized Feedback in the TheraNet Project

Mila Hall¹ · Lisa M. Lappenbusch² · Emily Wiegmann² · Julian A. Rubel¹

Accepted: 15 December 2023 / Published online: 23 January 2024
© The Author(s) 2024

Abstract

Background: Using idiographic network models in psychotherapy has been a growing area of interest. However, little is known about the perceived clinical utility of network models. The present study aims to explore therapists' experiences with network model-based feedback within the context of the TheraNet Project. **Methods:** In total, 18 therapists who had received network-based feedback for at least 1 patient at least 2 months prior were invited to retrospective focus groups. The focus group questions related to how participation in the study influenced the therapeutic relationship, how the networks were used, and what might improve their clinical utility. The transcribed focus groups were analyzed descriptively using qualitative content analysis. **Results:** Most therapists mentioned using the feedback to support their existing case concept, while fewer therapists discussed the feedback directly with the patients. Several barriers to using the feedback were discussed, as well as various suggestions for how to make it more clinically useful. Many therapists reported skepticism with regards to research in the outpatient training center in general, though they were also all pleasantly surprised by being involved, having their opinions heard, and showing a readiness to adapt research to their needs/abilities. **Conclusions:** This study highlights the gap between researchers' and therapists' perceptions about what useful feedback should look like. The TheraNet therapists' interest in adapting the feedback and building more informative feedback systems signals a general openness to the implementation of clinically relevant research. We provide suggestions for future implementations of network-based feedback systems in the outpatient clinical training center setting.

Was sind Ecological Momentary Interventions (EMI)?

- EMI: **mobilbasierte Interventionen**, die den Menschen in ihrem **Alltag**, also in ihrer natürlichen Umgebung, und auf einen **konkreten Moment/Tag** bezogen angeboten werden (in "Echtzeit")
- Unterschied zu IMI (vgl. Vorlesung von Patricia Garatva) liegt vor allem im *momentary*-Teil, d.h. dass die Interventionen an bestimmten Momenten/Tagen vorgegeben werden
- Begriff auch eher in der Forschung üblich als in der psychotherapeutischen Praxis
- Personalisierung möglich hinsichtlich Timing und Art der Intervention:
 - **Timing:** z.B. wenn ESM/EMA deutliche Veränderungen in relevanten pathologischen Prozessen widerspiegelt
 - **Art:** Auf eine Art und Weise, die in Anbetracht dessen, was über die Person bekannt ist, maximal effektiv ist

Beispiel für Einsatz von EMI in der Partnerschaftsforschung

Eliciting Short-Term Closeness in Couple Relationships With Ecological Momentary Interventions

Caroline Zygar-Hoffmann¹ , Lara Cristoforo¹, Lisa Wolf¹, Felix D. Schönbrodt¹ 

¹ Department of Psychology, Ludwig-Maximilians-Universität München, Munich, Germany

Keywords: state relationship closeness, intimacy, ecological momentary interventions, couples, experience sampling method

<https://doi.org/10.1525/collabra.38599>

Collabra: Psychology


Vol. 8, Issue 1, 2022

Ein Beispiel-EMI aus dem Paper:

"Nehmen Sie sich heute in einem ruhigen Moment etwas Zeit zusammen mit Ihrem Partner. Stellen Sie einen Wecker auf 5 Minuten und schauen Sie Ihrem Partner *für 5 Minuten in die Augen*. Alternativ können Sie auch Videochatten. Konzentrieren Sie sich dabei voll und ganz auf Ihren Partner."

Computer und mentale Gesundheit

- Idee, Computer einzusetzen, um Diagnostik und Prognostik von Erkrankungen zu verbessern, ist nicht neu



Arthur Radlow (60er Jahre): Machine Psychiatry aus „Closer than we think“.


- Idee: einen Computer zu füttern mit allen Wesensäußerungen des Patienten.
- Computer lernt aus den unterschiedlichsten Kombinationen von emotionalen Ausdrücken, Kognitionen und Verhalten, Entscheidungsregeln abzuleiten
- Die Kliniker:in kann diese verwenden, um Therapie danach auszurichten.

- Dichte an Informationen, die wir über Erkrankungen haben – nicht nur über psychische Erkrankungen, sondern generell über Erkrankungen – nimmt exponentiell zu
- **Kapazitätsproblem:** menschliche Kapazität mit diesem Wissen umzugehen ist begrenzt (Schere verfügbares vs. kognitiv verarbeitbares Wissen)

Big Data und Machine-Learning

Big Data

- **Definition:** große Datenmengen, die zu komplex sind, um sie mit traditionellen Methoden zu verarbeiten.
- umfasst sowohl strukturierte als auch unstrukturierte Daten, wie z.B. Text, Bilder, Audio- und Videodateien.
- Neue Technologien ermöglichen es, big data zu speichern und zu verarbeiten.
- **Ziel:** Muster, Trends und Verbindungen in den Daten zu erkennen und zu nutzen.




Machine Learning

- Computerstrategie, die **automatisch** Methoden und Parameter bestimmt (d.h. lernt), um eine optimale Lösung für ein Problem zu finden
- Wird nicht von vornherein von einem Menschen programmiert, um eine fixe Lösung zu liefern.
- Wird als Teilgebiet der künstlichen Intelligenz (KI) betrachtet
- Lernprozess simuliert vermeintlich eine Facette der menschlichen Intelligenz
- Kann für vermeintlich intelligente Zwecke eingesetzt werden (z.B. Sprache, Schrift, Gesichtserkennung, selbstfahrende Autos oder medizinische Entscheidungshilfen).

Machine Learning - die Anfänge

Das Perzeptron:

- Ziel: eine Maschine zu bauen, die ihre eigenen Formeln entwickelt, um Probleme durch Lernen zu lösen (Rosenblatt, 1958)
- Aufgabe: Bilder von Dreiecken von Quadraten unterscheiden mittels 400 Lichtsensoren
- Unterscheidung von Dreiecken von Quadraten nicht explizit programmiert → Training über **Trial und Error** Prozess



→ In den Anfängen des maschinellen Lernens ging es also darum, dass eine Maschine mit Hilfe realer Daten lernt begrenzte Vorannahmen darüber zu treffen, wie diese Daten aussehen, und dass die Leistung der Maschine unter realen Bedingungen bewertet wird.

<!--


--> <!-- --> <!-- -->

Machine Learning - die Anfänge

- Das Perzeptron trug dazu bei, die Betrachtungsweise von Computern zu ändern
- Vorher: Rechenmaschinen, die von vornherein mit bereits bekannten Formeln und Regeln programmiert werden mussten
- Nachher: Computer, die unscharfe Regeln selbständig erlernen konnten (z. B. Erkennung von Mustern).
- Dieser frühe Erfolg löste einen großen Hype aus, der größtenteils aus phantasievollen Verallgemeinerungen der zugrundeliegenden Logik auf andere Probleme bestand
- Die Seifenblase platzte jedoch, als sich die Hoffnungen aufgrund der Beschränkungen der frühen Algorithmen und der damals verfügbaren Rechenleistung nicht erfüllten.
- Einige dieser Beschränkungen können nun aufgrund der gestiegenen Rechenleistung überwunden werden, so dass es Maschinen möglich ist aus manchmal sehr komplexen Daten zu lernen.
- Machine Learning Algorithmen sind heute in unser tägliches Leben integriert: Internet-Suchen, Produktempfehlungen, Spracherkennungsdienste, selbstfahrende Autos, Bildklassifikation, Sprachmodelle (z.B. DeepL), Generative Modelle (z.B. ChatGPT)

Machine Learning - Entwicklungen im Gesundheitswesen

- Hoffnung, auch klinische Entscheidungsfindung durch Informationsverarbeitung zu verbessern
- **Präzisionsmedizin (tailored treatments):** Richtige Behandlung für richtige Patient:in zur richtigen Zeit




Machine Learning - Entwicklungen im Gesundheitswesen

- Ansatz des maschinellen Lernens im Gesundheitswesen funktioniert insbesondere gut bei Aufgaben, bei denen es um **Mustererkennung in Bildern** geht
- ML ebenso gut oder besser abgeschnitten als Kliniker, etwa bei
 - Erkennung von Hautkrebs (Esteva et al. 2017)
 - Lungenkrebs (Yu et al. 2016)
 - Brustkrebs (z. B. Samsung, RS80A)
 - Augenerkrankungen (Long et al. 2017)
- Und in der Psychologie? **Besonders für das Ziel der Vorhersage sehr relevant!** (für das Ziel der Erklärung weniger, da die Modelle selbst oft eine "Black Box" sind) → vielversprechende Forschung

Machine Learning - Entwicklungen im Gesundheitswesen

Psychologisches Beispiel: Vorhersage von Schizophrenie-Onset im Prodrom (Koutsouleris et al. 2021)



Klassen von Machine Learning


Man unterscheidet im Machine Learning i.d.R. drei unterschiedliche Anwendungsbereiche:

- **Unsupervised Learning:**

- Beinhaltet keine vorgegebenen Labels oder Zielvariablen.
- Ziel ist es, unbekannte Strukturen oder Muster in den Daten zu entdecken.
- Beispiele: Clustering, Dimensionality Reduction.

- **Supervised Learning:**

- Beinhaltet vorgegebene Labels oder Zielvariablen.
- Ziel ist es, ein Modell zu entwickeln, das in der Lage ist, neue Datenpunkte richtig vorherzusagen. → "**Prädiktive Modellierung**"
- Beispiele: Regression, Klassifikation.



- **Reinforcement/Reward Learning:**

- Beinhaltet ein Agent-System, das in einer Umgebung agiert und Entscheidungen trifft.
- Ziel ist es, das Verhalten des Agenten so anzupassen, dass es möglichst hohe Belohnungen erhält.
- Beispiele: Game-playing, Robotics.


→ Es ist zu beachten, dass diese drei Arten von Machine Learning-Methoden nicht immer klar voneinander abgegrenzt sind und es auch überlappende Anwendungen gibt.

Klassen von Machine Learning


Unsupervised Learning und Supervised Learning

- Lassen sich noch auf klassische statistische Fragestellungen zurückführen
- Output dieser Algorithmen ist eine Kategorie, bzw. eine Zahl
- **Unsupervised Learning:** Gruppierungsvorschläge für chaotische Datenstrukturen, ohne Vorkenntnis von Kategorien (Clustering) → wichtig für Entdeckung neuer Krankheitsmuster etc.
- **Supervised Learning:** versucht bereits bekannte Kategorien in Daten anhand anderer Informationen in den Daten wiederzuerkennen/vorherzusagen → wichtig für klinische Prognosen/Diagnosen

Unsupervised



Supervised




Klassen von Machine Learning

Logik der Prädiktiven Modellierung

Szenario:

- Wir haben einen Trainingsdatensatz mit Brainscans
- Wir wissen für Personen im Trainingsdatensatz, wer eine Diagnose hatte (rot) und wer nicht (blau)
- Prädiktion: Für neue Person (nicht im Datensatz) auf Basis der Brainscans vorhersagen, ob Diagnose vorhanden




Klassen von Machine Learning

Logik der Prädiktiven Modellierung

Schritt 1: Training

- Im Trainingsdatensatz das Modell auf Basis der Aktivierungsmuster im Brainscan trainieren
- Das heißt, das Modell versucht anhand der vorhandenen Daten herauszufinden woran es Personen mit und ohne tatsächliche Diagnose unterscheiden kann



Klassen von Machine Learning


Logik der Prädiktiven Modellierung

Schritt 2: Evaluierung

- Prüfen, ob durch das Modell die tatsächliche Diagnose von Personen **im Trainingsdatensatz** vorhersagen kann (d.h. ob in den Daten überhaupt Informationen vorhanden sind, anhand derer eine Vorhersage möglich ist).

Genauigkeitsmaße

- gesamte Vorhersagegenauigkeit = **Accuracy**
- Vorliegen von tatsächlicher Diagnose korrekt erkennen = **Sensitivität**
- Abwesenheit von tatsächlicher Diagnose korrekt erkennen = **Spezifität**



		Truth		
		Positive	Negative	
Predicted	Positive	True Positive	False Positive	Positive Predictive Value $= \frac{TP}{TP+FP}$
	Negative	False Negative	True Negative	Negative Predictive Value $= \frac{TN}{FN+TN}$
		True Positive Rate (Sensitivity) $= \frac{TP}{TP+FN}$	True Negative Rate (Specificity) $= \frac{TN}{FP+TN}$	Accuracy $= \frac{TP+TN}{n_{\text{test}}}$

Klassen von Machine Learning

Logik der Prädiktiven Modellierung

Schritt 3: Validierung


- **Prüfung der Generalisierbarkeit:** Um zu prüfen, ob das trainierte Modell gut funktioniert, müssen wir es validieren
- **Validierung:** Modell an Fällen erproben die nicht im Trainingsset dabei waren (d.h. an bis dahin unbekannten Personen) → entweder man erhebt also neue Daten, oder man teilt einen vorhandenen Datensatz in ein Trainings- und ein Testset
- VORSICHT: strikte Trennung zwischen Trainings- und Testdaten (Data-Leakage) → sonst droht ein **Overfit** (Überanpassung an die Daten)
 - Unfairer Vorteil: Vorhersage von Fällen, die das Modell schon "kennt"
 - Modell würde sonst besser performen, als in der Realität

Klassen von Machine Learning

Logik der Prädiktiven Modellierung

Wie trenne ich einen vorhandenen Datensatz in ein Trainings- und Testset?

- Einfachstes Szenario: **Simple Split** → Datensatz wird z.B. 50/50 in Trainings- und Testdatensatz geteilt
 - Problem: Forscher könnte genau so trennen, dass Modell gut funktioniert (das wäre Schummeln)
- Lösung: **(k-fold) Nested-Cross-Validation**
 - Datensatz wird in k Folds geteilt (hier k=5)
 - Runde 1: Training: 1-4 Folds, Test: 5. Fold
 - Runde 2: Training: 1,2,3,5 Folds, Test: 4. Fold
 - Runde 3: Training: 1,2,4,5 Folds, Test: 3. Fold
 - ...
 - Am Ende Genauigkeitsmaße ausrechnen
- Vorteil: Kein Overfit + ganzer Datensatz kann ohne Data-Leakage genutzt werden




Klassen von Machine Learning

Logik der Prädiktiven Modellierung

Generalisierbarkeitspyramide:


- Je unterschiedlicher die Kontexte (z.B. zeitlich, geografisch, kulturell) von Training und Test Folds, desto generalisierbarer ist das Modell
- Leave-Site-out → Folds = einzelne Studienzentren: Modell funktioniert nicht nur in Klinik A sondern auch in Klinik B
- External → Folds = einzelne Studien: Modell funktioniert nicht nur in Studie A sondern auch in Studie B
- Prospective → Folds = Zeit: Modell kann Fälle vorhersagen, die in der Zukunft liegen



Klassen von Machine Learning

Reinforcement Learning

- Beinhaltet das Erlernen von Funktionen und Entscheidungsregeln, um erhaltene Belohnungen zu maximieren (Fehler zu minimieren)
- Output dieser Algorithmen kann ein komplexes Verhalten sein
- Kann implizit auch Klassifikationen oder Gruppierungen beinhalten
- Beispiele sind Schach spielen lernen, autonomes Fahren, etc.




- Output: z.B. Lenkrad links/rechts drehen
- Objective Function: schnell ans Ziel ohne Unfall/Risiko

Mensch-Maschine Interaktion

Analogie: Stufen autonomen Fahrens

Stufe	Name	Interaktion
0	No automation	Fehlen von Assistenzsystemen.
1	Driver assistance	Systeme, die dem Fahrer helfen, die Geschwindigkeit zu halten oder in der Spur zu bleiben, aber dem Fahrer die Kontrolle überlassen.
2	Partial automation	Die Kombination aus automatischer Geschwindigkeits und Lenkung - zum Beispiel Tempomat und Spurhaltung.
3	Conditional automation	Automatisierte Systeme, die die Umgebung steuern und überwachen, aber auf einen menschlichen Fahrer als Unterstützung angewiesen sind.
4	High automation	Automatisierte Systeme, die alles erledigen - ohne menschliche Unterstützung - aber nur unter bestimmten Umständen.
5	Full automation	Der echte elektronische Chauffeur: Er behält die volle Kontrolle über das Fahrzeug, braucht keine menschliche Unterstützung und fährt unter allen Bedingungen.

Mensch-Maschine Interaktion



- Stufe 5, d. h. eine vollständige Automatisierung ohne die Möglichkeit der Unterstützung von Klinikpersonal ist nicht das Ziel.
- Auch Stufe 4 mit menschlicher Unterstützung unter sehr begrenzten Bedingungen ist nicht das Ziel.
- Angestrebt werden Synergieeffekte, d. h. die Kombination von Funktionen, die Maschinen am besten erledigen, mit solchen, die am besten für Kliniker:innen geeignet sind.

Klinische Akzeptanz von KI (Koutsouleris, 2021)

Anforderungen:

- Medizinische KI muss mindestens so **genau** sein wie menschliche Heuristik
- KI muss mindestens so **generalisiert** sein wie klinische Entscheidungsfindungen
- KI muss so trainiert werden, dass sie zu einer **effektiven Nutzung** bestehender Ressourcen führt
- Die **Anwendungsindikation** von medizinischer KI muss klar definiert ist
- Der **Bias** von KI muss offen gelegt werden können
- KI muss **transparent** bezüglich der eigenen **Unsicherheit** sein, um übermäßiger Technikgläubigkeit vorzubeugen
- KI muss **handlungsrelevante Informationen** produzieren
- KI muss **klinisch kontrolliert** werden können (was eine entsprechende Ausbildung im Studium erfordert)

- **Ambulatory Assessment (AA)** ist die wiederholte Erfassung von psychologischer (Kontext-)Variablen in natürlicher Umgebung.
- Der Zeitpunkt einer ESM/EMA Erhebung kann gemäß dem **Signal-contingent sampling** oder **Event-contingent sampling** vorgegeben werden.
- **Ecological Momentary Interventions (EMI)** sind alltagsnahe, auf den Moment/Tag bezogene Interventionen
- **Machine Learning:** Computerfunktionalität, die nicht explizit programmiert wurde, sondern selbstständig "lernt".
- **Unsupervised ML** → Mustererkennung, **Supervised ML** → Prädiktion, **Reinforcement Learning** → Operation
- Vorhersagegenauigkeit (**Accuracy**, **Sensitivität** und **Spezifität**) eines Prädiktionsmodells muss mittels **Validierung** auf neuen Daten geprüft werden.
- **Overfit:** Überanpassung an die Daten → führt zu veringelter Generalisierbarkeit.

Schlüssel-/Fachbegriffe der heutigen Vorlesung

Ambulatory Assessment

Experience Sampling Methode (ESM)

Ecological Momentary Assessment (EMA)

Mobile bzw. Ambient Sensing

Time-/Signal-contingent sampling

Event-contingent sampling

Fixed scheme

Random scheme

Ecological Momentary Interventions (EMI)

Kapazitätsproblem

Big Data

Machine Learning (ML)

Perzeptron

Präzisionsmedizin (tailored treatments)

Unsupervised ML

Supervised ML / Prädiktive Modellierung

Reinforcement/Reward Learning

Trainings- und Testdatensatz

Accuracy

Sensitivität

Spezifität

Generalisierbarkeit

Overfit

Kreuzvalidierung (CV)

Simple Split

(k-fold) Nested-Cross-Validation

Generalisierbarkeitspyramide

Leave-Site-Out CV

External validation

Prospective CV

[zurück zur heutigen Übersicht der Vorlesung →](#)

[zum Quiz zur Wissensprüfung →](#)

Sitzung am 05.02.2025: Zusammenfassung + Fragestunde

Damit die Zeit in dieser Stunde gut genutzt werden kann, würde ich Sie bitten Ihre Fragen zur Vorlesung in folgenden Dokument zu sammeln: <https://docs.google.com/document/d/1tWKYDSsRBc7MxoYnH4Cm6tyCBMkouVYjc0NMcGWDKfY/edit>

Je nach Fragen-Aufkommen werde ich dann Fragen priorisieren und versuchen daraus eine interaktive Lern-Möglichkeit für alle zu schaffen.

Ich habe ChatGPT um ein Bild für die Fragestunde gebeten. Hier das Ergebnis:

